Dataset — Desafio 1 (ETL, Limpeza e Enriquecimento)

Arquivo: `clientes_distribuidora_vetor.csv` (47 registros fictícios)

Todas as empresas, CNPJs, e-mails e nomes de vendedores são fictícios. Os CEPs usados nas variações "corretas" são reais (dados públicos dos Correios), para que a consulta a APIs como ViaCEP ou BrasilAPI durante o desafio retorne resultados de verdade.

Colunas

Coluna	**Descrição**
`id_cliente`	Identificador único do cliente
`razao_social`	Nome fictício do cliente (varejista atendido pela distribuidora)
`cnpj`	CNPJ fictício — formatos inconsistentes de propósito (com/sem máscara, com espaços)
`telefone`	Telefone fictício — formatos inconsistentes de propósito (fixo, celular, com/sem DDI, com/sem máscara)
`email`	E-mail fictício derivado do nome do cliente
`bairro_informado`	Bairro em texto livre, como foi digitado no cadastro — **é o campo central do desafio**

Coluna	Descrição
`cep`	CEP informado no cadastro — pode estar ausente, inválido, ou não bater com o `bairro_informado`
`cidade` / `uf`	Sempre Brasília/DF nesta amostra
`data_cadastro`	Data de cadastro — formatos inconsistentes de propósito (ISO, BR, texto em inglês)
`vendedor_responsavel`	Vendedor fictício responsável pelo cliente

O que foi inserido de propósito (sem entregar a solução)

- Múltiplas grafias para os mesmos bairros reais do DF (Águas Claras, Taguatinga, Vicente Pires, Guará), incluindo variações de caixa, acentuação, abreviações e subdivisões oficiais dos Correios que não são óbvias à primeira vista.
- Registros com CEP ausente.
- Registros com CEP em formato inválido.
- Registros em que o CEP presente **não corresponde** ao bairro informado em texto livre — conflito proposital entre as duas fontes.
- Um grupo de bairro (Guará) sem CEP confiável disponível na amostra — simula o caso de dado estruturalmente incompleto, não apenas malformatado.
- Formatos distintos de CNPJ, telefone e data dentro do mesmo dataset.

O que NÃO está aqui

- Não há gabarito de "bairro correto" por linha — a equipe decide seus próprios critérios de canonicalização e documenta o raciocínio.
- Não há schema de banco pré-definido — a modelagem da tabela final e da tabela de auditoria é parte do desafio.

Sugestão de uso

O dataset pode ser carregado diretamente em Python (`pandas.read_csv`) ou importado num banco Postgres para começar o pipeline de ETL.